

数值计算实验1

数据科学与计算机学院

梁育诚

学号 16340133

班级 教务二班

内容1

请实现下述算法，求解线性方程组 $Ax=b$ ，其中 A 为 $n \times n$ 维的已知矩阵， b 为 n 维的已知向量， x 为 n 维的未知向量。

- (1) 高斯消元法。
 - (2) 列主元消去法。
- A 与 b 中的元素服从独立同分布的正态分布。令 $n=10、50、100、200$ ，测试计算时间并绘制曲线。

问题描述（高斯消元法）

对于一个这样的线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases} \quad (1.1)$$

，或写成矩阵形式

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

，简记为 $Ax = b$ 。
我们可以使用高斯消元法来进行求解。

算法设计（高斯消元法）

高斯消元法主要分为消元和回代两个部分。消元的目的是把 A 矩阵变成一个上三角矩阵，回代的目的是利用已知的 x 去求解每一行中仅有的一个未知的 x 。

- (1) 第一步 ($k=1$)
设 $a_{11}^{(1)} \neq 0$ ，首先计算乘数

$$m_{i1} = a_{i1}^{(1)} / a_{11}^{(1)}, i = 2, 3, \dots, n.$$

用 $-m_{i1}$ 乘方程组 (1.1) 的第1个方程，加到第 i 个 ($i = 2, 3, 4, \dots, n$) 方程上，消去方程组 (1.1) 的从第2个方程到第 n 个方程中的未知数 x_1 ，得到与方程组 (1.1) 等价的线性方程组：

$$\begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(2)} \\ \vdots \\ b_n^{(2)} \end{bmatrix}$$

简记为

$$A^{(2)}x = b^{(2)},$$

其中， $A^{(2)}$ ， $b^{(2)}$ 的元素计算公式为

$$\begin{cases} a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i1}a_{1j}^{(1)}, i, j = 2, 3, \dots, n. \\ b_i^{(2)} = b_i^{(1)} - m_{i1}b_1^{(1)}, i = 2, 3, \dots, n. \end{cases}$$

- (2) 第 k 次消元 ($k = 1, 2, \dots, n - 1$)
假设第 $k - 1$ 步已经完成，我们有如下线性方程组：

$$\begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} \\ & & \ddots & \vdots & & \vdots \\ & & & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ & & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(2)} \\ \vdots \\ b_k^{(k)} \\ \vdots \\ b_n^{(k)} \end{bmatrix},$$

简记为 $A^{(k)}x = b^{(k)}$.

设 $a_{kk}^{(k)} \neq 0$, 计算乘数

$$m_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)}, i = k+1, k+2, \dots, n.$$

用 $-m_{ik}$ 乘方程组第 k 个方程, 并加到第 i 个方程 ($i = k+1, \dots, n$), 消去从第 $k+1$ 个方程到第 i 个方程中的未知数 x_k , 得到 $A^{(k+1)}x = b^{(k+1)}$. 其中 $A^{(k+1)}$, $b^{(k+1)}$ 元素的计算公式为:

$$\begin{cases} a_{ij}^{(k+1)} = a_{ij}^{(k)} - m_{ik}a_{kj}^{(k)}, i, j = k+1, \dots, n. \\ b_i^{(k+1)} = b_i^{(k)} - m_{ik}b_k^{(k)}, i = k+1, \dots, n. \end{cases}$$

显然 $A^{(k+1)}$ 中从第 1 行到第 k 行与 $A^{(k)}$ 相同。

(3) 经过 $n-1$ 步消元计算后, 我们得到 $A^{(n)}x = b^{(n)}$:

$$\begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(2)} \\ \vdots \\ b_n^{(n)} \end{bmatrix},$$

若 A 是非奇异矩阵, 且 $a_{kk}^{(k)} \neq 0$ ($k = 1, 2, \dots, n-1$), 求解矩阵的回代公式为:

$$\begin{cases} x_n = b_n / a_{nn}^{(n)}, \\ x_k = b_k^{(k)} - \sum_{j=k+1}^n a_{kj}^{(k)} x_j / a_{kk}^{(k)}, k = n-1, n-2, \dots, 1. \end{cases}$$

这样, 高斯的消元与回代就结束了, 我们就可以得到 x 的解。

问题描述 (列主元消元法)

在上述高斯消元法中不难发现, 在每一次的消元步骤中, 我们都需要除以当前列的主元。如果这个主元是一个非常小的数, 那么这样将会导致精度丢失, 影响算法的稳定性。因此我们需要一个改进的方法, 就是列主元消元法, 其基本的思路和高斯消元法一致, 不同之处在于每一步的消元前, 都选取该列中绝对值最大的元素作为主元, 这样可以保证数值较小的数不会丢失精度。

算法设计 (列主元消去法)

由于算法的大部分与高斯消元法类似, 在这里只讲述不同的地方。

对于 $k=1, 2, \dots, n-1$

① 按列选绝对值最大的元素作为主元:

$$|a_{i_k, k}| = \max_{k \leq i \leq n} |a_{ik}|$$

② 如果 $a_{i_k, k} = 0$, 则停止计算。

③ 如果 $i_k = k$, 则说明当前元素是主元, 无需交换, 执行④

交换 A 中的行和对应 b 中的元素: $a_{kj} \leftrightarrow a_{i_k, j} (j = k, k+1, \dots, n)$

$$b_k \leftrightarrow b_{i_k}$$

将上述步骤放在高斯消元法每次消元步骤之前即可。

数值实验

编写好高斯消元法和列主元消元法的matlab代码, 随机生成矩阵。以矩阵的维数 n 为横坐标, 以求解每个矩阵的运行时间作为纵坐标, 进行作图分析, 对比两个算法的数值稳定性。

高斯消元法:

```

1. function[x]=gauss_elim(A,b)
2. % A为系数矩阵且必须为方阵
3. % b为常数项向量
4. n=size(A,1);
5. x=zeros(1,n);
6. %分解
7. for k=1:n
8.     %顺序主子式为0, 则退出
9.     w=det(A(1:k,1:k))
10.    if (w==0)
11.        return;
12.    end
13.    %若主元为0, 则换一个
14.
15.    if(A(k,k)==0)
16.        t=min(find(A(k+1:n,1)~=0+k));
17.        if isempty(t)
18.            return
19.        end;
20.        temp=A(k,:);tb=b(k);
21.        A(k,:)=A(t,:);b(k)=b(t);
22.        A(t,:)=temp;b(t)=tb;
23.    end;
24.
25.    for i=k+1:n
26.        m=A(i,k)/A(k,k);
27.        for j=k+1:n
28.            A(i,j)=A(i,j)-m*A(k,j);
29.        end
30.        b(i) = b(i)-m*b(k);
31.    end
32. end
33.
34. %回代
35. x(n)=b(n)/A(n,n);
36. for i=n-1:-1:1
37.     sum = 0;
38.     for j=i+1:n
39.         sum = sum + A(i,j)*x(j);
40.     end
41.     x(i) = (b(i)-sum)./A(i,i);
42. end

```

列主元消元法:

```

1. function[x] = gauss_elim_pro(A, b)
2. % A为系数矩阵且必须为方阵
3. % b为常数项向量
4.
5. n=length(b);
6. x=zeros(n,1);
7. c=zeros(1,n);
8.
9. %分解
10. for i = 1: n
11.     %顺序主子式为0, 则退出
12.     w=det(A(1:i,1:i))
13.     if (w==0)
14.         return;
15.     end
16.     max=abs(A(i,i));
17.     m = i;
18.     for j = i + 1:n
19.         if max < abs(A(j,i))
20.             max = abs(A(j,i));
21.             m = j;
22.         end
23.     end
24.     %如果最大的主元不在本行, 需要交换
25.     if (m ~= i)
26.         for k = i:n
27.             c(k) = A(i,k);
28.             A(i,k)=A(m,k);
29.             A(m,k)=c(k);
30.         end
31.         d1 = b(i);
32.         b(i)=b(m);
33.         b(m)=d1;
34.     end

```

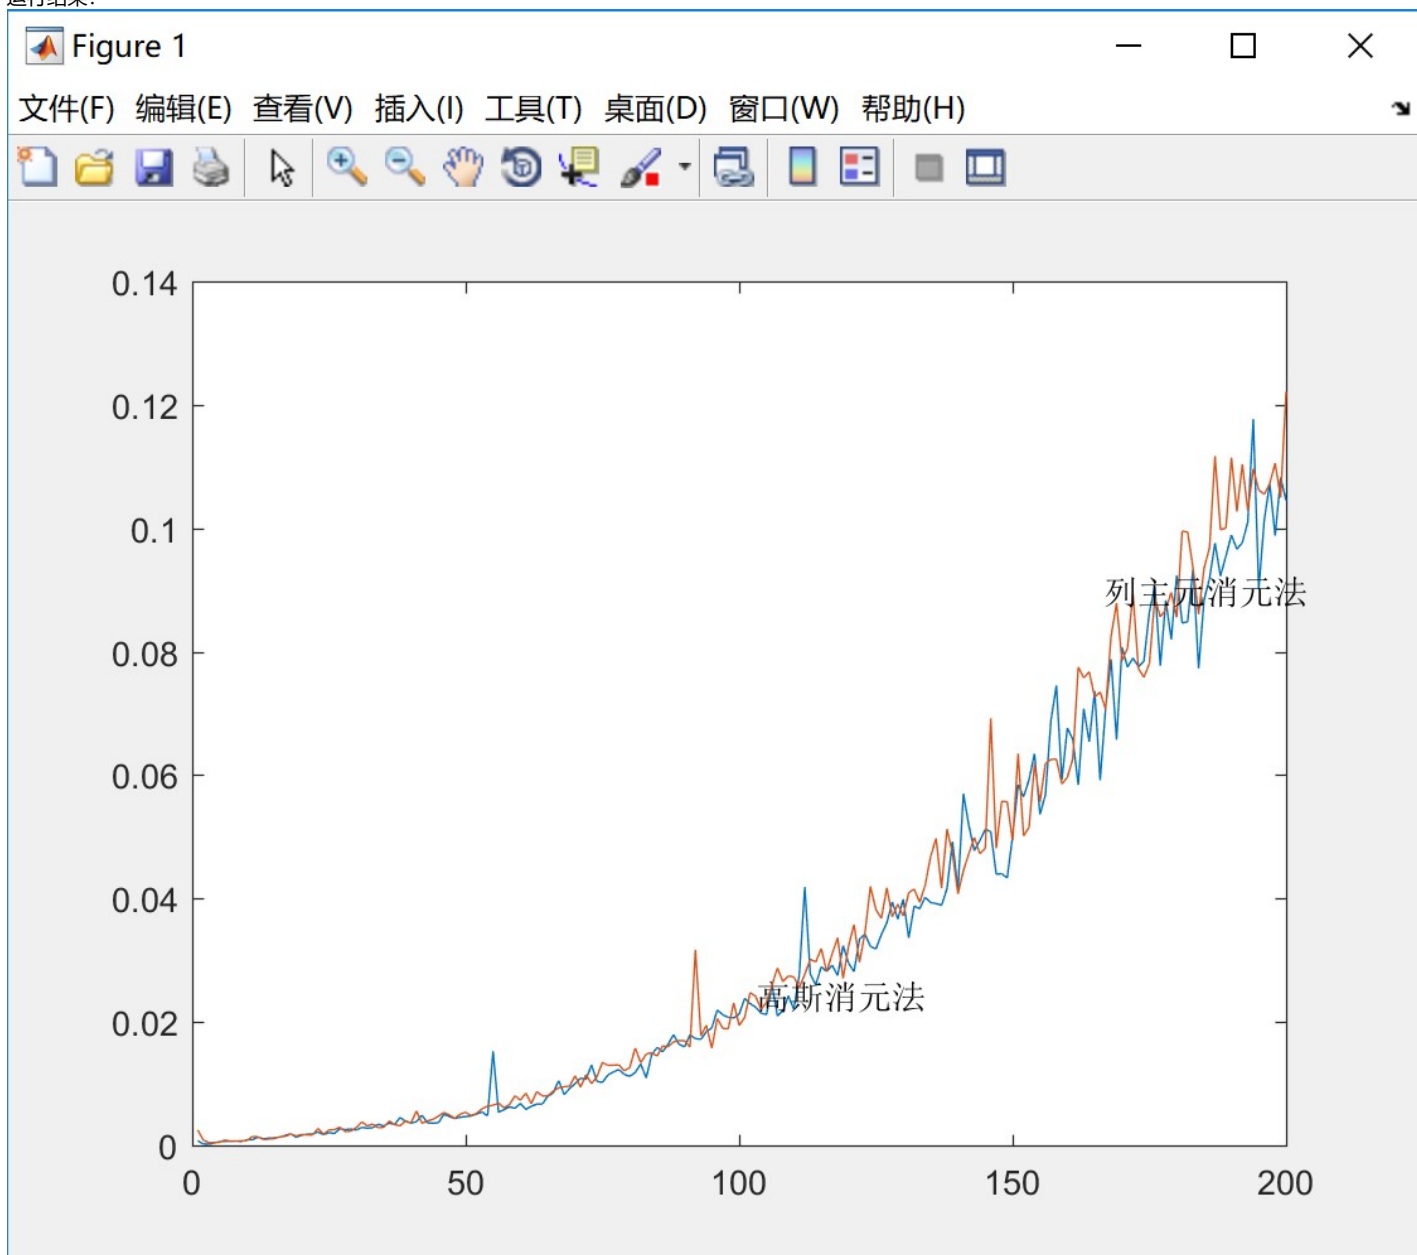
```

35.
36.     for k = i+1:n
37.         for j = i+1:n
38.             A(k, j) = A(k, j)-A(i, j)*A(k, i) ./ A(i, i);
39.         end
40.         b(k)=b(k)-b(i)*A(k, i) ./ A(i, i);
41.         A(k, i)=0;
42.     end
43. end
44.
45. % 回代
46. x(n)=b(n)/A(n, n);
47. for i = n-1:-1:1
48.     sum=0;
49.     for j=i+1:n
50.         sum = sum + A(i, j)*x(j);
51.     end
52.     x(i)=(b(i)-sum) ./ A(i, i);
53. end

```

结果分析

运行结果:



其中蓝线是高斯消元法，橙线是列主元消元法。可以看出，两条线几乎是重叠的，这也说明两个算法在时间上是差不多的，但是列主元消元法的线更平滑一些，但是整体比高斯消元法的线高一些，这些说明了列主元消元法牺牲时间以换取更好的数值稳定性，其中的时间就花在了寻找列主元上。

内容2

请实现下述算法，求解线性方程组 $Ax=b$ ，其中 A 为 $n \times n$ 维的已知矩阵， b 为 n 维的已知向量， x 为 n 维的未知向量。

- (1) Jacobi 迭代法。
- (2) Gauss-Seidel 迭代法。
- (3) 逐次超松弛迭代法。
- (4) 共轭梯度法。

A 与 b 中的元素服从独立同分布的正态分布。令 $n=10, 50, 100, 200$ ，分别绘制出算法的收敛曲线，横坐标为迭代步数，纵坐标为相对误差。比较 Jacobi 迭代法、Gauss-Seidel 迭代法、逐次超松弛迭代法、共轭梯度法与高斯消去法、列主元消去法的计算时间。改变逐次超松弛迭代法的松弛因子，分析其对收敛速度的影响。

问题描述

这部分我们要实现和分析的求解矩阵的迭代法。考虑现行方程组 $Ax=b$ ，其中 A 为非奇异矩阵，当 A 是**低阶稠密矩阵**时，可以使用内容一中的高斯消去法以及列主元消去法来进行求解。但是，当 A 是**高阶稀疏矩阵**时，就可以利用迭代法来进行求解。迭代法利用了 A 中零元素较多的特点。

算法设计（雅可比迭代法）

首先我对迭代法的思路进行大致的分析，后续算法中就不再赘述。对于一个线性方程组，第 k 行中，如果我已知除 x_k 之外的其余 $x_i (i \neq k)$ ，那么我就可以根据这个方程把 x_k 求解出来。因此，我可以首先假设已知 x_0 ，然后不断重复以上的步骤，即迭代，最终可以求得一个解。如果这个矩阵是具有收敛性质的，那么这个解 x 就可以无限逼近精确解 x^* 。

我们通过变换，可以将 $Ax=b$ 等价变换为 $x^* = Bx + f$ 。构造向量序列

$$x^{(k+1)} = Bx^{(k)} + f$$

，其中 k 表示迭代次数。

如果 $\lim_{x \rightarrow \infty} x^{(k)}$ 存在，则说明**迭代法收敛**，否则，该**迭代法发散**。所以我们每次使用迭代法求解矩阵的时候就需要判断矩阵是否收敛。

这里给出一个判断矩阵收敛的定理：对于一个线性方程组，迭代法收敛的充要条件是矩阵 B 的谱半径 $\rho(B) < 1$ 。

现在我来讲解雅可比迭代法。雅可比迭代法是对上述迭代过程的详细展开。对于线性方程组的系数矩阵 A ，可分解为三部分：

$$A = \begin{bmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & \ddots & & \\ & & & a_{nn} & \end{bmatrix} - \begin{bmatrix} 0 & & & & \\ -a_{21} & 0 & & & \\ \vdots & \vdots & \ddots & & \\ -a_{n-1,1} & -a_{n-1,2} & \cdots & 0 & \\ -a_{n1} & -a_{n2} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} - \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1,n-1} & -a_{1n} \\ & 0 & \cdots & -a_{2,n-1} & -a_{2n} \\ & & \ddots & \vdots & \vdots \\ & & & 0 & -a_{n-1,n} \\ & & & & 0 \end{bmatrix} = D - L - U$$

设 $a_{ii} \neq 0 (i = 1, 2, \dots, n)$ ，可以得到 $Ax=b$ 的雅可比迭代法：

$$\begin{cases} x^{(0)}, \text{初始向量} \\ x^{(k+1)} = Bx^{(k)} + f, k = 0, 1, \dots, \end{cases}$$

其中 $B = I - D^{-1}A = D^{-1}(L + U) = J, f = D^{-1}b$ ，称 J 为解 $Ax=b$ 的雅可比迭代法的迭代矩阵。

解 $Ax=b$ 的雅可比迭代法的计算公式为：

$$\begin{cases} x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T \\ x_i^{(k+1)} = (b_i - \sum_{j=1, j \neq i}^n a_{ij}x_j^{(k)}) / a_{ii}, \\ i = 1, 2, \dots, n; k = 0, 1, \dots \text{表示迭代次数。} \end{cases}$$

根据上述计算公式就可以使用雅可比迭代法求解了。

算法设计（高斯-赛德尔迭代法）

高斯-赛德尔迭代法可以看作是对雅可比迭代法的优化改进。它的思路在于，更新每一步 x_i 的时候，可以利用已经更新 $x_j (j < i)$ 的值，这样可以减少迭代次数，因为它计算每一个分量的时候是基于当前的最新分量。

设 $a_{ii} \neq 0 (i = 1, 2, \dots, n)$ ，可以得到 $Ax=b$ 的高斯-赛德尔迭代法：

$$\begin{cases} x^{(0)}, \text{初始向量} \\ x^{(k+1)} = Bx^{(k)} + f, k = 0, 1, \dots, \end{cases}$$

其中 $B = I - (D - L)^{-1}A = (D - L)^{-1}U = G, f = (D - L)^{-1}b$ 。称 $G = (D - L)^{-1}U$ 为解 $Ax = b$ 的高斯赛德尔迭代法的迭代矩阵。

求解 $Ax=b$ 的高斯赛德尔迭代法计算公式为

$$\begin{cases} \mathbf{x}^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T, \text{ 初始向量} \\ x_i^{(k+1)} = (b_i - \sum_{j=1, j \neq i}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)}) / a_{ii}, \\ i = 1, 2, \dots, n; k = 0, 1, \dots \text{ 表示迭代次数。} \end{cases}$$

这就是高斯赛德尔迭代法的计算公式。

算法设计（超松弛迭代法）

超松弛迭代法，SOR，是对于高斯赛德尔迭代法的改进。它的关键之处在于松弛因子 ω ，这个因子可以控制收敛的方向来控制迭代速度和迭代精度。由于迭代速度和迭代精度是相互矛盾的，如果我想得到更快的迭代速度（倾向于向新的 x 靠近），那么我就有可能偏离了我的正确值；如果我追求迭代精度（倾向于向旧的 x 靠近）那么，我的迭代速度就很慢。松弛因子 ω 就是用来调节这两者的，务求找到一个平衡点。这里直接给出SOR的计算方法。

$$\begin{cases} \mathbf{x}^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T, \text{ 初始向量} \\ x_i^{(k+1)} = x_i^{(k)} + \omega(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)}) / a_{ii}, \\ i = 1, 2, \dots, n; k = 0, 1, \dots \text{ 表示迭代次数,} \\ \omega \text{ 为松弛因子} \end{cases}$$

使用SOR的时候，需要注意的是矩阵A必须是对称正定矩阵，同时 $0 < \omega < 2$ 。

算法设计（共轭梯度法）

谈到共轭梯度法，首先要了解与线性方程组等价的变分问题。

设 $A = (a_{ij}) \in R^{n \times n}$ 是对称正定矩阵， $b = (b_1, b_2, \dots, b_n)^T$ ，求解的线性方程组为 $Ax=b$ 。考虑如下定义的二次函数

$$\varphi(x) = \frac{1}{2} (Ax, x) - (b, x)$$

，该函数等价于对应的线性方程组。

性质1：对一切 $x \in R^n$ ， $\varphi(x)$ 的梯度为

$$\nabla \varphi(x) = Ax - b$$

性质2：对一切 $x, y \in R^n$ 及 $\alpha \in R$,

$$\begin{aligned} \varphi(x + \alpha y) &= \frac{1}{2} (A(x + \alpha y), x + \alpha y) - (b, x + \alpha y) \\ &= \varphi(x) + \alpha(Ax - b, y) + \frac{\alpha^2}{2} (Ay, y) \end{aligned}$$

性质3：设 $x^* = A^{-1}b$ 是线性方程组 $Ax=b$ 的解，则

$$\varphi(x^*) = -\frac{1}{2} (b, A^{-1}b) = -\frac{1}{2} (Ax^*, x^*)$$

，且对一切 $x \in R^n$ ，有

$$\begin{aligned} \varphi(x) - \varphi(x^*) &= \frac{1}{2} (Ax, x) - (Ax^*, x) + \frac{1}{2} (Ax^*, x^*) \\ &= \frac{1}{2} (A(x - x^*), x - x^*) \end{aligned}$$

根据上述二次函数的性质，我们可以知道，当 x^* 为令 $\varphi(x)$ 最小时， x^* 是该方程的解。这样，我们就把求解矩阵的问题转化为求解二次函数极小值点的问题

共轭梯度法的思想是，对于初始的一个 x ，使用方向 $p^{(0)}, p^{(1)}, \dots, p^{(k-1)}$ 进行 k 次搜索，求得 $x^{(k)}$ ，然后确定 $p^{(k)}$ 的方向，这样能使 $x^{(k+1)}$ 更快地求得 x^* 。其主要迭代公式为：

$$\begin{aligned} x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)}, \\ x^{(k)} &= \alpha_0 p^{(0)} + \alpha_1 p^{(1)} + \dots + \alpha_{k-1} p^{(k-1)}. \end{aligned}$$

α_k 的值可以根据如下公式计算：

因为我们每步的求解过程中，都需要基于当前的 x ，求出下一个极小值，即

$$\varphi(x^{(k+1)}) = \min_{\alpha \in R} \varphi(x^{(k)} + \alpha p^{(k)})$$

，由于

$$\varphi(x^{(k)} + \alpha p^{(k)}) = \varphi(x^{(k)}) + \alpha(Ax^{(k)} - b, p^{(k)}) + \frac{\alpha^2}{2} (Ap^{(k)}, p^{(k)})$$

，对上式求导，求出极小值

$$\frac{d\varphi(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})}{d\alpha} = (A\mathbf{x}^{(k)} - \mathbf{b}, \mathbf{p}^{(k)}) + \alpha(A\mathbf{p}^{(k)}, \mathbf{p}^{(k)}) = 0,$$

解得

$$\alpha_k = -\frac{(A\mathbf{x}^{(k)} - \mathbf{b}, \mathbf{p}^{(k)})}{(A\mathbf{p}^{(k)}, \mathbf{p}^{(k)})}$$

又因为我们希望 $\mathbf{p}^{(k)}$ 能使 $\mathbf{x}^{(k+1)}$ 能够更快地求得 \mathbf{x}^* , 因此我们有

$$\varphi(\mathbf{x}^{(k+1)}) = \min_{\mathbf{x} \in \text{span}\{\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k)}\}} \varphi(\mathbf{x})$$

然后我们把 \mathbf{x} 分解成 $\mathbf{x} = \mathbf{y} + \alpha \mathbf{p}^{(k)}$, 所以得到

$$\varphi(\mathbf{x}) = \varphi(\mathbf{y} + \alpha \mathbf{p}^{(k)}) = \varphi(\mathbf{y}) - \alpha(A\mathbf{y}, \mathbf{p}^{(k)}) - \alpha(\mathbf{b}, \mathbf{p}^{(k)}) + \frac{\alpha^2}{2}(A\mathbf{p}^{(k)}, \mathbf{p}^{(k)})$$

由于我们需要对 \mathbf{x} 求导, 又因为 \mathbf{x} 用 \mathbf{y} 来表示, 所以对 \mathbf{y} 求偏导。因为要为0, 所以交叉项 $(A\mathbf{y}, \mathbf{p}^{(k)})$ 必须为0, 这样一组向量 \mathbf{p} 称为**共轭向量**。

以上就是对于共轭梯度法的核心思想的分析。下面直接给出算法:

(1) 任取初始向量 $\mathbf{x}^{(0)}$, 一般取为0, 计算 $\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)}$, $\mathbf{p}^{(0)} = \mathbf{r}^{(0)}$ 。

(2) 对 $k = 0, 1, \dots$, 计算

$$\begin{aligned}\alpha_k &= \frac{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}{(\mathbf{p}^{(k)}, A\mathbf{p}^{(k)})} \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)} \\ \mathbf{r}^{(k+1)} &= \mathbf{r}^{(k)} - \alpha_k A\mathbf{p}^{(k)}, \beta_k = \frac{(\mathbf{r}^{(k+1)}, \mathbf{r}^{(k+1)})}{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})} \\ \mathbf{p}^{(k+1)} &= \mathbf{r}^{(k+1)} + \beta_k \mathbf{p}^{(k)}\end{aligned}$$

(3) 若 $\mathbf{r}^{(k)} = \mathbf{0}$, 或 $(\mathbf{p}^{(k)}, A\mathbf{p}^{(k)}) = 0$, 则计算停止, 得出结果。

这就是共轭梯度法的简要算法分析。

数值实验

迭代法依赖于程序的循环结构, 对于迭代法我们要设置迭代结束的标志, 为了测试需要, 每个迭代法可以自定义迭代的次数以用作迭代结束的判断。在正规的迭代中, 迭代的结束标志应该是一个误差的范围。

雅可比迭代

```
1. function[xn]=jacobi(A,b,max)
2. n=size(A,1);
3. eps = 0.000001;
4. if nargin == 2
5.     max = 200;
6. end
7. x0=zeros(n,1);
8. xn=zeros(n,1);
9. x0(1)=1;
10. %{
11. D = diag(diag(A)); % 求A的对角矩阵
12. L = -tril(A, -1); % 求A的下三角矩阵
13. U = -tril(A, 1); % 求A的上三角矩阵
14. B = D\ (L+U);
15. f = D\b;
16. x = B*x0+f;
17. %}
18. times = 0;% 迭代次数
19. while norm(xn-x0)>=eps && times <= max
20.     times=times+1;
21.     x0=xn;
22.
23.     for i=1:n
24.         sum = 0;
25.         for j =1:n
26.             if (j~=i)
27.                 sum = sum + A(i, j) * x0(j);
28.             end
29.         end
30.         xn(i)=(b(i)-sum)/A(i, i);
31.     end
32.
33.     if(times>=max)
34.         return;
35.     end
```

```

36. end
37. disp(times);
38. disp(xn);

```

高斯赛德尔迭代

```

1. function[xn]=Gauss_Seidel(A,b, max)
2. n=size(A,1);
3. if nargin == 2
4.     max = 200;
5. end
6. eps = 0.000001;
7.
8. x0=zeros(n,1);
9. xn=zeros(n,1);
10. x0(1)=1;
11. %{
12. D = diag(diag(A)); % 求A的对角矩阵
13. L = -tril(A, -1); % 求A的下三角矩阵
14. U = -tril(A,1); % 求A的上三角矩阵
15. B = D\ (L+U);
16. f = D\b;
17. x = B*x0+f;
18. %}
19. % 判断有没有唯一解
20. if det(A) == 0
21.     return;
22. end
23.
24. times = 0;% 迭代次数
25. while norm(xn-x0)>=eps && times <= max
26.     times=times+1;
27.     x0=xn;
28.
29.     for i=1:n
30.         sum1 = 0;
31.         sum2 = 0;
32.         for j =1:i-1
33.             sum1 = sum1 + A(i, j) * xn(j);
34.         end
35.         for j=i+1:n
36.             sum2 = sum2 + A(i, j) * x0(j);
37.         end
38.         xn(i)=(b(i) - sum1 - sum2)/A(i, i);
39.     end
40.
41.     if(times>=max)
42.         return;
43.     end
44. end
45. disp(times);
46. disp(xn);

```

超松弛迭代

```

1. function[xn]=SOR(A,b,w,max)
2. n=size(A,1);
3. eps = 0.000001;
4. if nargin == 3
5.     max = 200;
6. end
7. x0=zeros(n,1);
8. xn=zeros(n,1);
9. x0(1)=1;
10. %{
11. D = diag(diag(A)); % 求A的对角矩阵
12. L = -tril(A, -1); % 求A的下三角矩阵
13. U = -tril(A,1); % 求A的上三角矩阵
14. B = D\ (L+U);
15. f = D\b;
16. x = B*x0+f;
17. %}
18. times = 0;% 迭代次数
19. while norm(xn-x0)>=eps && times <= max
20.     times=times+1;
21.     x0=xn;
22.
23.     for i=1:n
24.         sum1 = 0;

```



```

25.         sum2 = 0;
26.         for j =1:i-1
27.             sum1 = sum1 + A(i, j) * xn(j);
28.         end
29.         for j=i:n
30.             sum2 = sum2 + A(i, j) * x0(j);
31.         end
32.         xn(i)=x0(i) + w * (b(i) - sum1 - sum2)/A(i, i);
33.     end
34.
35.     if(times>=max)
36.         return;
37.     end
38. end
39. disp(times);
40. disp(xn);

```

共轭梯度法

```

1. function[x] = CG(A,b,max)
2. n = size(A,1);
3. x0 = zeros(n,1);
4. r0=b-A*x0;
5. p0=r0;
6.
7. if nargin == 2
8.     max = 200;
9. end
10. eps = 1.0e-6;
11. times = 0;
12. while 1
13.     if ((abs(p0) < eps))
14.         break;
15.     end
16.     if (times > max)
17.         break;
18.     end
19.     times = times + 1;
20.     a0 = (r0' * r0) / (p0' * A*p0); % 多次使用
21.     x1 = x0 + a0*p0;
22.
23.     r1 = r0 - a0*A*p0;
24.
25.     b0 = (r1'*r1)/(r0'*r0);
26.
27.     p1 = r1 + b0 *p0;
28.
29.     %只是用到前后两层的向量，所以节省内存开销，计算完后面    一层，可以往回覆盖掉没用的变量
30.     x0 = x1;
31.     r0 = r1;
32.     p0 = p1;
33. end
34. x = x0;
35. end


```

结果分析


四个迭代法的误差分析对比

随机生成维数 $n=10,50,100,200$ 四个矩阵，对于每一个矩阵，分用雅可比迭代法、高斯赛德尔迭代法、超松弛迭代法、共轭梯度法四种方法进行求解，记录迭代次数与误差。以迭代次数为横坐标，相对误差为纵坐标，作图。


$n=10$




n=20



n=100



$n=200$



蓝线为雅可比迭代；橙线为高斯赛德尔迭代；黄线为超松弛迭代；紫线为共轭梯度法

从以上四幅图可以很清晰的看出，四种迭代法中，雅可比迭代的收敛速度最慢，共轭梯度的收敛速度最快。高斯赛德尔迭代法和SOR不确定，这是因为SOR迭代法的迭代速度由松弛因子 ω 控制，对于不同矩阵有不同的最佳松弛因子，又因为测试中我设置了固定的松弛因子，所以SOR的收敛速度有时候比高斯赛德尔迭代法快，有时候比高斯赛德尔迭代法慢。

六个求解方程组算法的时间比较

对比六种算法对同一个矩阵的求解计算时间：

$n = 10$

方法	时间
雅可比迭代法	0.0002
高斯赛德尔迭代法	0.0003
SOR迭代法	0.0003
共轭梯度法	0.0001
高斯消元法	0.00013
列主元消元法	0.0008

$n = 100$

方法	时间
----	----

方法	时间
雅可比迭代法	0.0053
高斯赛德尔迭代法	0.0044
SOR迭代法	0.0048
共轭梯度法	0.0040
高斯消元法	0.0189
列主元消元法	0.0192

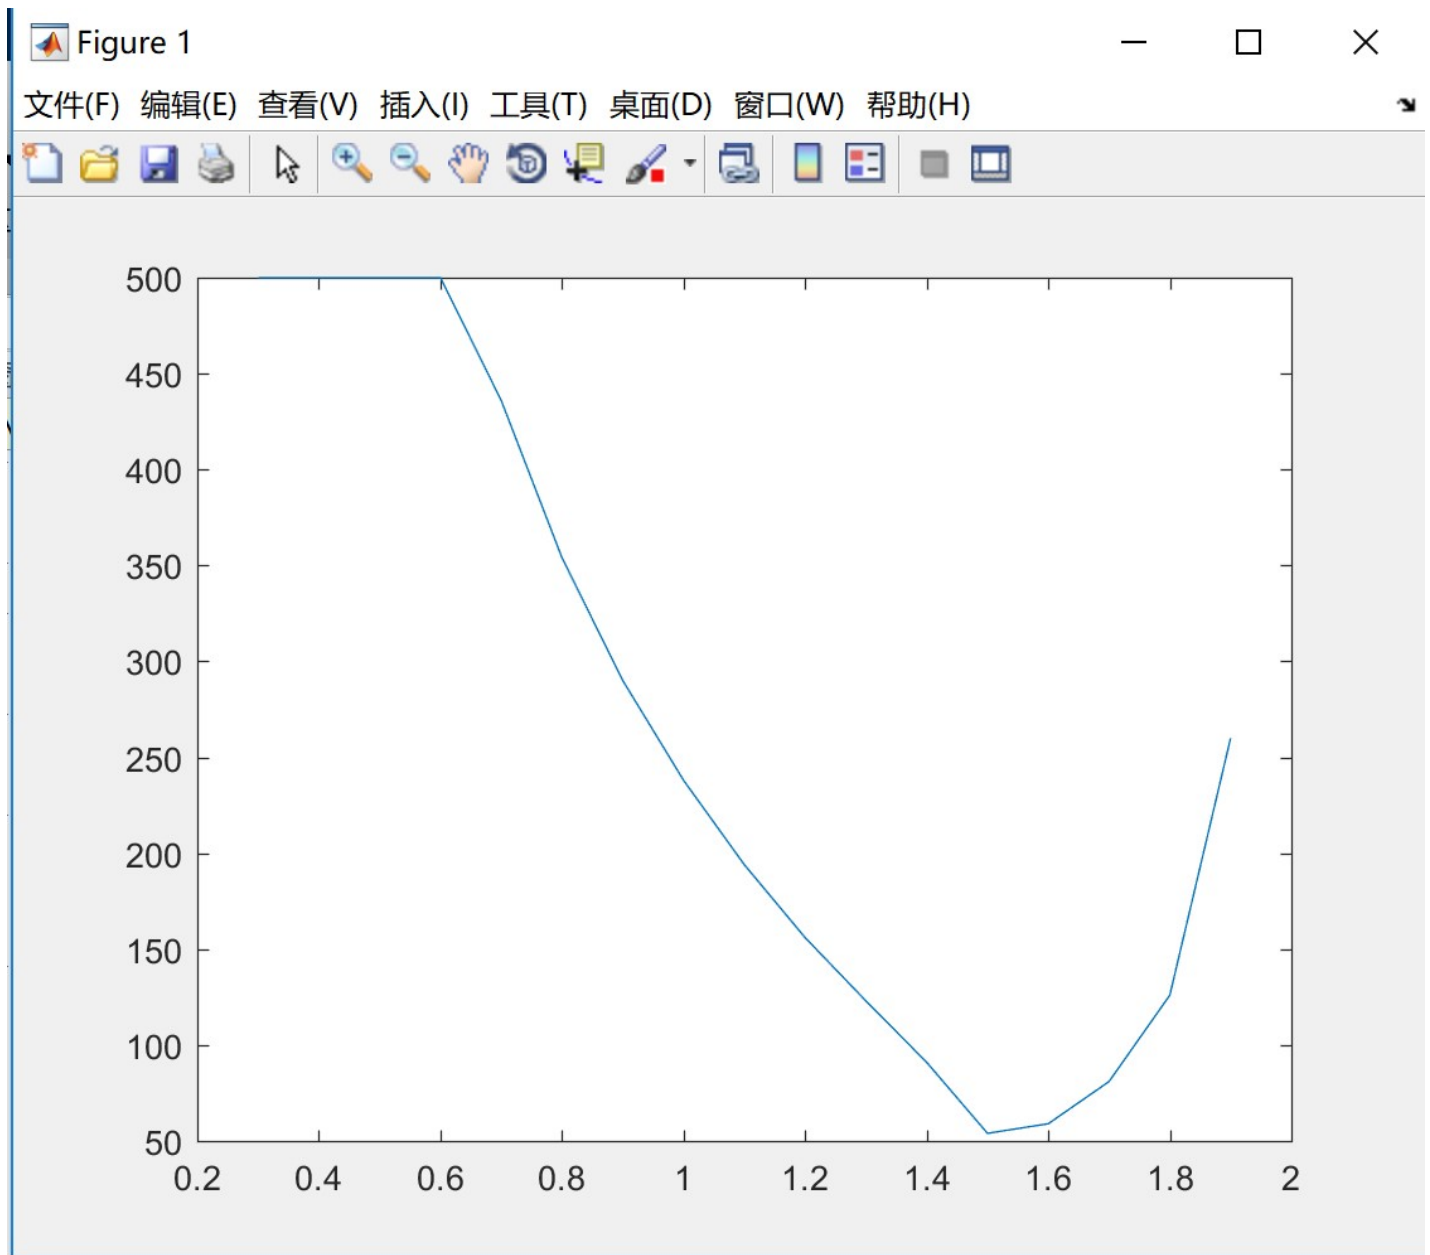
n = 200

方法	时间
雅可比迭代法	0.0254
高斯赛德尔迭代法	0.0128
SOR迭代法	0.0120
共轭梯度法	0.0036
高斯消元法	0.1311
列主元消元法	0.1069

可以看出，迭代法的计算速度普遍较快，尤其是计算高维矩阵的时候，优势更加明显。其中，共轭梯度法的计算速度最快。

ω 对迭代速度的影响

这个测试是为了研究不同的 ω 对SOR的速度的影响。这里采用测量迭代次数的方法，即对于不同omega，看看哪个算法的误差小于某个指定的值，记录当时的迭代次数，对于每次迭代我给了最高的迭代次数500。
结果如下：



从图中可以看出，对于测试用的这个矩阵，最佳的松弛因子 ω 是1.5。对于不同的矩阵，最佳松弛因子是不同的。

内容3

PageRank介绍

pagerank算法是目前谷歌搜索引擎使用的网页排名算法，它的作用是对现有的各种网站进行一个基于重要度的排序，然后把结果返回给搜索用户。

首先pagerank基于两个基本假设：**数量假设**和**质量假设**。数量假设，是说一个页面的入链越多，它就越重要。质量假设，一个页面的重要性，不仅由入链的数量决定，而且也受入链质量决定。入链的质量越高，这个页面越重要。其中，一个页面的PR值，即前面所说的重要性，为它的入链重要性之和。所以我们就得到了这样的一个模型：**一个页面的得票数由所有链向它的页面的重要性来决定，到一个页面的链接相当于对该页面投了一票。一个页面的PageRank是由所有链向它的页面的重要性经过递归得到的。**

大致思路

1. 基于页面之间的指向关系，建立一个连通图，使用矩阵表示，这个矩阵称为**网页链接矩阵**。
2. 根据网页链接矩阵，可以计算出**网页链接概率矩阵**，即对于某一个网页而已，假设它的每一个跳转都是等概率的。每个网页的总权值为1。
3. 由于有的页面它不指向任何其它页面，因此需要增加阻尼系数 q ， q 一般取 $q=0.85$ 。它的实际意义是在任何时刻，用户从当前页面跳转到另一个页面的概率。
4. 最后利用**马可洛夫性质**通过不断的迭代，直到矩阵收敛，得出来的结果就是PageRank了，即网页排名。

伪代码

计算网页链接矩阵

$A[i][j] = 1$ if page i connect to page j
计算网页链接概率矩阵A

$$A[i][j] = \frac{1}{\sum outdegree(page(j))}$$

if page j connect to page i

while 没有满足精度

$A = (1 - q) + q \frac{1}{n} U$, U是元素全为1的n×n的矩阵
最后得到PageRank矩阵A

优缺点

PageRank是一个与查询无关的静态算法，所有网页的PageRank值通过离线计算获得；有效减少在线查询时的计算量，极大降低了查询响应时间。但是旧的页面等级会比新页面高。因为即使是非常好的新页面也不会有很多上游链接，除非它是某个上游站点的子站点。